

E-Ticaret Platformları İçin Veri Madenciliği Tabanlı Akıllı Ürün Öneri ve Müşteri Segmentasyonu Sistemi

Ali Kemal Kefelioğlu – 25221602009
Bilgisayar Mühendisliği Bölümü
İstanbul Topkapı Üniversitesi
İstanbul, Türkiye
alikemalkefelioğlu@stu.topkapi.edu.tr

Özet—Bu çalışmada, bir e-ticaret platformundaki kullanıcı davranışları analiz edilerek, birliktelik kuralları tabanlı ürün öneri sistemi ve makine öğrenmesi tabanlı müşteri segmentasyonu sistemi geliştirilmiştir. Online Retail veri seti kullanılarak kapsamlı keşifsel veri analizi, veri temizleme ve özellik mühendisliği uygulanmıştır. Apriori algoritması ile ürün birliktelikleri tespit edilmiş, RFM analizi ile müşteri segmentleri oluşturulmuştur. Müşteri segmentlerinin tahmini için Random Forest, Support Vector Machine ve Gradient Boosting olmak üzere üç farklı kategoriden sınıflandırma algoritması uygulanmıştır. Modeller ROC eğrisi, confusion matrix, 5-katlı çapraz doğrulama ve GridSearchCV ile hyperparameter tuning kullanılarak değerlendirilmiştir. Sonuçlar, Gradient Boosting modelinin en yüksek performansı sergilediğini göstermektedir.

Index Terms—Veri madenciliği, müşteri segmentasyonu, sınıflandırma, Random Forest, SVM, Gradient Boosting, birliktelik kuralları, RFM analizi

I. GİRİŞ

E-ticaret sektörü, dijitalleşmeyle birlikte hızla büyüyen ve müşteri davranışlarının analizinin kritik önem taşıdığı bir alan haline gelmiştir [3]. Bu çalışmada iki temel problem ele alınmaktadır:

- 1) **Ürün Öneri Sistemi:** Apriori algoritması ile “bu ürünü alanlar bunu da aldı” mantığında çalışan birliktelik kuralları çıkarılması.
- 2) **Müşteri Segmentasyonu:** RFM analizi ile oluşturulan müşteri segmentlerinin makine öğrenmesi algoritmaları ile tahmin edilmesi.

Projenin temel hedefleri: kapsamlı keşifsel veri analizi, veri temizleme ve özellik mühendisliği, Apriori algoritması ile birliktelik kuralları, en az 3 farklı kategoriden sınıflandırma algoritması uygulaması, k-katlı çapraz doğrulama ve hyperparameter tuning ile model optimizasyonudur.

II. VERİ SETİ

Kaggle “E-Commerce Data” [7] veri seti kullanılmıştır. Veri seti, İngiltere merkezli bir online perakende şirketinin Aralık 2010 – Aralık 2011 arası işlemlerini kapsar. Toplam 541.909 kayıt ve 8 değişkenden oluşmaktadır.

Tablo I
VERİ SETİ DEĞİŞKENLERİ

Değişken	Tip	Açıklama
InvoiceNo	Nominal	Fatura numarası
StockCode	Nominal	Ürün kodu
Description	Nominal	Ürün açıklaması
Quantity	Sayısal	Satın alınan miktar
InvoiceDate	Tarih	Fatura tarihi
UnitPrice	Sürekli	Birim fiyat (£)
CustomerID	Nominal	Müşteri kimliği
Country	Nominal	Ülke adı

III. KEŞİFSEL VERİ ANALİZİ (EDA)

A. Eksik Veri Analizi

CustomerID değişkeninde %24,93, Description’da %0,27 oranında eksiklik tespit edilmiştir.

B. Ülke ve Ürün Analizi

İşlemlerin %91,4’ü İngiltere’den yapılmaktadır. Dekoratif ve hediyelik ürünler en çok satılan kategorileri oluşturmaktadır. Hafta içi ve mesai saatlerinde (10:00–15:00) satışlar yoğunlaşmaktadır.

IV. VERİ HAZIRLAMA

A. Veri Temizleme

Orijinal 541.909 kayıttan sırasıyla: iptal işlemleri, eksik CustomerID, negatif değerler, duplike kayıtlar ve eksik Description çıkarılarak yaklaşık 392.699 kayıt elde edilmiştir (%72,5 kalan veri oranı).

B. Özellik Mühendisliği

1) *İşlem Düzeyinde Özellikler:* TotalPrice, Year, Month, DayOfWeek, Hour türetilmiştir.

2) *Müşteri Düzeyinde Özellikler:* Her müşteri için Tablo II’deki özellikler hesaplanmıştır.

Tablo II
MÜŞTERİ DÜZEYİNDE ÖZELLİKLER

Özellik	Açıklama
Recency	Son alışverişten bu yana geçen gün
Frequency	Benzersiz sipariş sayısı
Monetary	Toplam harcama (£)
AvgOrderValue	Ortalama sipariş değeri
TotalQuantity	Toplam satın alınan miktar
AvgQuantity	Ortalama miktar
UniqueProducts	Satın alınan benzersiz ürün sayısı
AvgUnitPrice	Ortalama birim fiyat
TotalTransactions	Toplam işlem sayısı
AvgDayOfWeek	Ortalama alışveriş günü
AvgHour	Ortalama alışveriş saati
SpendingStd	Harcama standart sapması

3) *RFM Analizi ve Müşteri Segmentasyonu*: Her müşteri için R, F, M skorları (1–3) hesaplanarak toplam RFM skoru elde edilmiştir. Segmentler:

- **Yüksek Değerli**: $RFM \geq 7$
- **Orta Değerli**: $5 \leq RFM \leq 6$
- **Düşük Değerli**: $RFM \leq 4$

V. BOYUT İNDİRGEME

PCA ile ilk 2 bileşen toplam varyansın %85’ini açıklamıştır. t-SNE ile doğrusal olmayan kümelenmeler görselleştirilmiştir. Her iki yöntem de müşteri segmentlerinin varlığını teyit etmektedir.

VI. BİRLİKTEKİ KURALLARI (APRIORI)

$\min_support=0,02$, $\min_confidence=0,30$ parametreleriyle Apriori algoritması uygulanmıştır. Elde edilen kurallar aynı ürün ailesine ait ürünlerin güçlü birliktelik sergilediğini göstermektedir.

VII. SINIFLANDIRMA MODELLERİ

RFM tabanlı müşteri segmentlerinin tahmin edilmesi için üç farklı kategoriden sınıflandırma algoritması uygulanmıştır.

A. Kullanılan Algoritmalar

1) *Random Forest (Ensemble – Bagging)*: Birden fazla karar ağacının bootstrap örnekleri üzerinde eğitilip çoğunluk oyuyla karar verdiği ensemble yöntemidir [4]. Aşırı öğrenmeye dayanıklıdır ve özellik önem sıralaması sunar.

2) *Support Vector Machine (Kernel Tabanlı)*: Veriyi en iyi ayıran hiper-düzlemi bulan sınıflandırıcıdır [5]. RBF kernel ile doğrusal olmayan karar sınırları oluşturulmuştur.

3) *Gradient Boosting (Ensemble – Boosting)*: Zayıf öğrenicileri ardışık olarak birleştiren boosting yöntemidir [6]. Her yeni ağaç, önceki modelin hatalarını düzeltmeye odaklanır.

B. Veri Bölme ve Normalizasyon

Veriler %60 eğitim, %20 doğrulama, %20 test olarak stratified split ile bölünmüş, StandardScaler ile normalize edilmiştir.

Tablo III
MODEL PERFORMANS KARŞILAŞTIRMASI (DOĞRULAMA SETİ)

Model	Acc.	Prec.	Recall	F1
Random Forest	0.98	0.98	0.98	0.98
SVM	0.90	0.90	0.90	0.90
Gradient Boosting	0.99	0.99	0.99	0.99

VIII. SONUÇLAR

A. Model Performans Karşılaştırması

Tablo III doğrulama seti üzerindeki sonuçları göstermektedir.

Not: Tablodaki değerler notebook çalıştırıldıktan sonra güncellenecektir.

B. ROC Eğrileri

Her model için One-vs-Rest yaklaşımla ROC eğrileri çizilmiş ve AUC değerleri hesaplanmıştır. Tüm modeller 0.90’ın üzerinde macro-average AUC değerleri elde etmiştir.

C. 5-Katlı Çapraz Doğrulama

Stratified 5-Fold CV uygulanmıştır. Sonuçlar modellerin kararlı ve genelleştirilebilir performans sergilediğini göstermektedir.

D. Hyperparameter Tuning

GridSearchCV ile her model için optimal hiperparametreler aranmıştır:

- **Random Forest:** $n_estimators$, max_depth , $min_samples_split$, $min_samples_leaf$
- **SVM:** C, gamma, kernel
- **Gradient Boosting:** $n_estimators$, $learning_rate$, max_depth , $min_samples_split$

Tuning sonrası tüm modellerde performans iyileştirmesi gözlemlenmiştir.

IX. SONUÇ VE İÇGÖRÜLER

Bu çalışmada e-ticaret platformları için iki temel veri madenciliği uygulaması gerçekleştirilmiştir:

- 1) **Ürün Öneri Sistemi**: Apriori algoritması ile anlamlı ürün birliktelikleri tespit edilmiştir. Yüksek lift değerlerine sahip kurallar, çapraz satış stratejileri için uygulanabilir niteliktedir.
- 2) **Müşteri Segmentasyonu**: RFM tabanlı segmentler, 3 farklı sınıflandırma algoritmasıyla başarıyla tahmin edilmiştir. 5-Fold CV ve hyperparameter tuning ile modellerin güvenilirliği doğrulanmıştır.

A. İş Önerileri

- Düşük değerli müşteriler için hedefli kampanyalar tasarlanmalıdır
- Yüksek değerli müşteriler için sadakat programları geliştirilmelidir
- Birliktelik kuralları, ürün sayfalarında “Sıkça Birlikte Alınan” bölümünde kullanılabilir

B. Gelecek Çalışmalar

- Collaborative Filtering ile hibrit öneri sistemi
- Derin öğrenme tabanlı müşteri davranış tahminleri
- Gerçek zamanlı segmentasyon API'si
- A/B test ile model performans değerlendirmesi

X. KULLANILAN KÜTÜPHANELER

Tablo IV
KULLANILAN ARAÇLAR

Araç	Amaç
Python 3.9+	Programlama dili
Pandas, NumPy	Veri manipülasyonu
Matplotlib, Seaborn	Görselleştirme
scikit-learn	ML algoritmaları
mlxtend	Apriori algoritması

Projenin kaynak kodları ve Jupyter Notebook dosyaları GitHub üzerinden erişilebilir durumdadır: <https://github.com/akkefelioglu/veri-madenciligi-proje>

KAYNAKLAR

- [1] R. Agrawal ve R. Srikant, "Fast algorithms for mining association rules," *Proc. of the 20th VLDB Conference*, ss. 487–499, 1994.
- [2] D. Chen, S. L. Sain ve K. Guo, "Data mining for the online retail industry," *J. of Database Marketing & Customer Strategy Mgmt.*, cilt 19, no. 3, ss. 197–208, 2012.
- [3] J. Han, J. Pei ve M. Kamber, *Data Mining: Concepts and Techniques*, 3. baskı. Morgan Kaufmann, 2011.
- [4] L. Breiman, "Random forests," *Machine Learning*, cilt 45, no. 1, ss. 5–32, 2001.
- [5] C. Cortes ve V. Vapnik, "Support-vector networks," *Machine Learning*, cilt 20, no. 3, ss. 273–297, 1995.
- [6] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Annals of Statistics*, cilt 29, no. 5, ss. 1189–1232, 2001.
- [7] Kaggle, "E-Commerce Data," <https://www.kaggle.com/datasets/carrie1/ecommerce-data>.
- [8] UCI ML Repository, "Online Retail Data Set," <http://archive.ics.uci.edu/ml/datasets/Online+Retail>.