

E-Ticaret Platformları İçin Veri Madenciliği Tabanlı Akıllı Ürün Öneri ve Kişiselleştirme Sistemi

Ali Kemal Kefelioğlu – 25221602009

Bilgisayar Mühendisliği Bölümü

İstanbul Topkapı Üniversitesi

İstanbul, Türkiye

alikemalkefelioglu@stu.topkapi.edu.tr

Özet—Bu çalışmada, bir e-ticaret platformundaki kullanıcı davranışları analiz edilerek, her kullanıcıya özel ürün önerileri sunan bir veri madenciliği tabanlı akıllı öneri sistemi geliştirilmiştir. Kaggle üzerinden elde edilen Online Retail veri seti kullanılarak kapsamlı bir keşifsel veri analizi (EDA) gerçekleştirilmiş, veri temizleme ve ön işleme adımları uygulanmıştır. Özellik mühendisliği kapsamında RFM (Recency, Frequency, Monetary) metrikleri oluşturulmuş, PCA ve t-SNE yöntemleriyle boyut indirgeme işlemleri yapılmıştır. Birliklilik Kuralları (Association Rules) çerçevesinde Apriori algoritması kullanılarak “bu ürünü alanlar bunu da aldı” mantığıyla çalışan bir öneri motoru tasarlanmıştır. Elde edilen kurallar support, confidence ve lift metrikleri ile değerlendirilmiştir. Sonuçlar, geliştirilen sistemin anlamlı ürün birliklilikleri tespit edebildiğini ve İleri Web Programlama dersindeki web projesine entegre edilebilir bir yapı sunabildiğini göstermektedir.

Index Terms—Veri madenciliği, birliklilik kuralları, Apriori algoritması, e-ticaret, ürün öneri sistemi, RFM analizi, keşifsel veri analizi

I. GİRİŞ

E-ticaret sektörü, dijitalleşmeyle birlikte hızla büyüyen ve kullanıcı davranışlarının analiz edilmesinin kritik önem taşıdığı bir alan haline gelmiştir. Kullanıcıların alışveriş geçmişleri, ürün tercihleri ve sepet davranışları, veri madenciliği teknikleriyle analiz edilerek kişiselleştirilmiş ürün önerileri sunulabilmektedir [3].

Birliklilik kuralları madenciliği, veri madenciliğinin en yaygın kullanılan tekniklerinden biridir ve “sepet analizi” olarak da bilinmektedir. Agrawal ve Srikant [1] tarafından önerilen Apriori algoritması, sık öge kümelerini ve bunlar arasındaki ilişkileri keşfetmek için kullanılan temel algoritmalarından biridir. Bu algoritma, büyük ölçekli işlem verilerinden anlamlı ürün birlikliliklerini ortaya çıkarma konusunda etkinliğini kanıtlamıştır.

Bu çalışmada, UCI Machine Learning Repository’den elde edilen Online Retail veri seti [4] kullanılarak bir e-ticaret platformundaki müşteri davranışları analiz edilmiş ve Apriori algoritması ile “bu ürünü alanlar bunu da aldı” mantığında çalışan bir akıllı ürün öneri sistemi geliştirilmiştir.

Projenin temel hedefleri şunlardır:

- Veri setinin kapsamlı keşifsel analizi (EDA) ve veri görselleştirme
- Veri temizleme ve ön işleme süreçlerinin uygulanması

- Özellik mühendisliği ve RFM analizi ile müşteri segmentasyonu
- Özellik seçimi ve boyut indirgeme (PCA, t-SNE)
- Apriori algoritması ile birliklilik kurallarının çıkarılması
- İleri Web Programlama dersindeki web projesine entegre edilebilir bir öneri motoru tasarımı

Çalışmanın geri kalan bölümleri şu şekilde organize edilmiştir: Bölüm II’de kullanılan veri seti tanıtılmaktadır. Bölüm III’te keşifsel veri analizi sunulmaktadır. Bölüm IV’te veri hazırlama süreçleri açıklanmaktadır. Bölüm V’te özellik seçimi, Bölüm VI’da boyut indirgeme yöntemleri ele alınmaktadır. Bölüm VII’de Apriori algoritması ve birliklilik kuralları detaylandırılmaktadır. Bölüm VIII’de model değerlendirme sonuçları, Bölüm IX’da ise sonuçlar ve gelecek çalışmalar tartışılmaktadır.

II. VERİ SETİ

A. Veri Seti Tanımı

Bu çalışmada Kaggle platformunda yayınlanan “E-Commerce Data” [4] veri seti kullanılmıştır. Bu veri seti aynı zamanda UCI Machine Learning Repository’de “Online Retail” [5] ismiyle de bulunmaktadır. Veri seti, İngiltere merkezli bir online perakende şirketinin 01/12/2010 – 09/12/2011 tarihleri arasındaki tüm işlemlerini kapsamaktadır. Şirket, ağırlıklı olarak benzersiz hediye eşyaları satan ve müşterilerinin büyük bölümü toptancılardan oluşan bir e-ticaret platformudur.

B. Veri Seti Özellikleri

Veri seti toplam 541.909 kayıt ve 8 değişkenden oluşmaktadır. Tablo I veri setindeki değişkenlerin detaylarını göstermektedir.

C. Meta-data Bilgileri

Veri setinin genel istatistikleri Tablo II’de özetlenmiştir.

III. KEŞİFSEL VERİ ANALİZİ (EDA)

A. Eksik Veri Analizi

Veri setindeki eksik değerler incelendiğinde, iki değişkende eksik değer tespit edilmiştir: CustomerID değişkeninde 135.080 kayıt (%24,93), Description değişkeninde ise 1.454

Tablo I
VERİ SETİ DEĞİŞKENLERİ VE AÇIKLAMALARI

Değişken	Tip	Açıklama
InvoiceNo	Nominal	6 haneli fatura numarası. "C" ile başlayanlar iptal işlemlerini temsil eder.
StockCode	Nominal	5 haneli ürün kodu. Her ürüne benzersiz olarak atanmıştır.
Description	Nominal	Ürün açıklaması (ürün adı).
Quantity	Sayısal	Her bir işlemde satın alınan ürün miktarı.
InvoiceDate	Tarih	Faturanın oluşturulduğu tarih ve saat.
UnitPrice	Sürekli	Birim ürün fiyatı (sterlin cinsinden).
CustomerID	Nominal	Müşteriye benzersiz olarak atanan 5 haneli kimlik numarası.
Country	Nominal	Müşterinin ikamet ettiği ülke adı.

Tablo II
VERİ SETİ META-DATA BİLGİLERİ

Özellik	Değer
Toplam kayıt sayısı	541.909
Değişken sayısı	8
Bellek kullanımı	~48 MB (CSV)
Zaman aralığı	Aralık 2010 – Aralık 2011
Benzersiz fatura sayısı	25.900
Benzersiz müşteri sayısı	4.372
Benzersiz ürün sayısı	3.958
Ülke sayısı	38

kayıt (%0,27) eksiktir. Diğer değişkenlerde eksik veri bulunmamaktadır. Eksik veri analizi sonuçları Tablo III'de sunulmuştur.

CustomerID'deki yüksek eksiklik oranı, bazı müşterilerin üyelik oluşturmadan alışveriş yaptığını göstermektedir. Bu kayıtlar müşteri bazlı analizler için kullanılamayacağından, ilgili adımda veri setinden çıkarılmıştır.

B. Ülke Bazlı Analiz

İşlemlerin ülkelere göre dağılımı incelendiğinde, büyük çoğunluğunun İngiltere'den (United Kingdom) yapıldığı görülmüştür. Tablo IV en fazla işlem yapan 10 ülkeyi göstermektedir.

İngiltere'nin toplam işlemlerden aldığı pay %91,4 olup, veri setinin ağırlıklı olarak İngiltere merkezli bir e-ticaret platformuna ait olduğunu teyit etmektedir.

C. Ürün Analizi

En çok satılan ürünler incelendiğinde, dekoratif ve hediyeelik ürünlerin ön plana çıktığı görülmüştür. Tablo V en çok satılan ilk 10 ürünü göstermektedir.

D. Zaman Serisi Analizi

Aylık satış trendleri incelendiğinde, Kasım 2011'de belirgin bir satış artışı gözlemlenmiştir. Bu durum, Kara Cuma (Black Friday) ve Noel öncesi alışveriş döneminin etkisini yansıtmaktadır. Haftalık analizde, hafta içi günlerde (özellikle Perşembe ve Salı) satışların daha yoğun olduğu; saatlik analizde ise 10:00–15:00 aralığının en yoğun alışveriş saatleri olduğu tespit edilmiştir.

Tablo III
EKSİK VERİ ANALİZİ

Değişken	Eksik Sayı	Oran (%)
CustomerID	135.080	24,93
Description	1.454	0,27
InvoiceNo	0	0,00
StockCode	0	0,00
Quantity	0	0,00
InvoiceDate	0	0,00
UnitPrice	0	0,00
Country	0	0,00

Tablo IV
EN FAZLA İŞLEM YAPAN İLK 10 ÜLKE

Ülke	İşlem Sayısı
United Kingdom	495.478
Germany	9.495
France	8.557
EIRE (İrlanda)	8.196
Spain	2.533
Netherlands	2.371
Belgium	2.069
Switzerland	2.002
Portugal	1.519
Australia	1.259

E. Sayısal Değişkenlerin İstatistiksel Özeti

Quantity ve UnitPrice değişkenlerinin istatistikleri Tablo VI'da sunulmuştur.

Her iki değişkende de sağa çarpık (right-skewed) bir dağılım gözlemlenmiş ve aykırı değerlerin varlığı tespit edilmiştir. Negatif Quantity değerleri iade/iptal işlemlerini, negatif UnitPrice değerleri ise düzeltme kayıtlarını temsil etmektedir.

F. Korelasyon Analizi

Sayısal değişkenler arasındaki Pearson korelasyon katsayıları hesaplanmıştır. Quantity ve TotalPrice arasında pozitif bir ilişki ($r = 0,62$) bulunmuştur. UnitPrice ve Quantity arasında ise ihmal edilebilir düzeyde bir korelasyon ($r = -0,02$) gözlemlenmiştir. Bu durum, fiyatın satın alınan miktar üzerinde belirleyici bir etken olmadığını göstermektedir.

IV. VERİ HAZIRLAMA (DATA PREPROCESSING)

A. Veri Temizleme (Data Cleaning)

Orijinal 541.909 kayıttan aşağıdaki temizleme adımları sırasıyla uygulanmıştır. Her adımdaki değişim Tablo VII'de özetlenmektedir.

Temizleme sürecinde her adımın gerekçesi şu şekildedir:

- İptal işlemleri:** "C" ile başlayan fatura numaraları iade veya iptal edilen işlemleri temsil etmekte olup, bu kayıtlar gerçek satın alma davranışını yansıtmadığından çıkarılmıştır.
- Eksik CustomerID:** Müşteri bazlı analiz yapılabilmesi için müşteri kimliği zorunludur; bu bilgiye sahip olmayan kayıtlar analize dahil edilmemiştir.
- Negatif değerler:** $Quantity \leq 0$ ve $UnitPrice \leq 0$ olan kayıtlar hatalı veya düzeltme amaçlı kayıtlardır.

Tablo V
EN ÇOK SATILAN İLK 10 ÜRÜN

Ürün Açıklaması	Miktar
WHITE HANGING HEART T-LIGHT HOLDER	53.847
REGENCY CAKESTAND 3 TIER	12.484
JUMBO BAG RED RETROSPOT	47.363
PARTY BUNTING	45.066
LUNCH BAG RED RETROSPOT	35.334
ASSORTED COLOUR BIRD ORNAMENT	36.381
SET OF 3 CAKE TINS PANTRY DESIGN	36.039
PACK OF 72 RETROSPOT CAKE CASES	36.039
LUNCH BAG BLACK SKULL	33.643
NATURAL SLATE HEART CHALKBOARD	30.359

Tablo VI
SAYISAL DEĞİŞKENLERİN İSTATİSTİKSEL ÖZETİ

İstatistik	Quantity	UnitPrice	TotalPrice
Ortalama	9,55	4,61	17,99
Std. Sapma	218,08	96,76	378,76
Min	-80.995	-11.062	-
%25	1	1,25	3,40
Medyan	3	2,08	9,75
%75	10	4,13	17,40
Max	80.995	38.970	-

- 4) **Duplike kayıtlar:** Birebir aynı olan satırlar veri bütünlüğünü bozmamak için çıkarılmıştır.
- 5) **Eksik Description:** Ürün açıklaması olmayan kayıtlar birliktelik analizi için kullanılamayacağından çıkarılmıştır.

B. Özellik Mühendisliği (Feature Engineering)

Mevcut değişkenlerden yeni özellikler türetilmiştir:

- **TotalPrice:** Her bir satır için Quantity $\times$ UnitPrice formülü ile toplam tutar hesaplanmıştır.
- **Zaman Özellikleri:** InvoiceDate değişkeninden Year, Month, DayOfWeek ve Hour özellikleri çıkarılmıştır.
- **RFM Metrikleri:** Her müşteri için aşağıdaki metrikler hesaplanmıştır:
 - *Recency (R):* Son alışverişten bu yana geçen gün sayısı
 - *Frequency (F):* Toplam benzersiz fatura (sipariş) sayısı
 - *Monetary (M):* Toplam harcama tutarı (£)

RFM analizi, müşteri segmentasyonu ve davranış modellemesi için yaygın olarak kullanılan bir çerçevedir [2]. Tablo VIII RFM metriklerinin istatistiksel özetini sunmaktadır.

RFM analizi sonuçları, müşterilerin farklı segmentlere ayrılabilirliğini göstermektedir. Yüksek Frequency ve Monetary değerlerine sahip müşteriler platformun sadık ve değerli müşterilerini oluşturmaktadır.

V. ÖZELLİK SEÇİMİ (FEATURE SELECTION)

Apriori algoritması için ürün uzayının daraltılması gerekmektedir. Düşük frekanslı ürünler, istatistiksel olarak güvenilir birliktelik kuralları üretmeyeceğinden elenmiştir. Frekans eşiği analizi Tablo IX'da gösterilmiştir.

Tablo VII
VERİ TEMİZLEME ADIMLARI VE ETKİLERİ

Temizleme Adımı	Silinen	Kalan
Orijinal veri seti	-	541.909
İptal işlemleri çıkarma (C ile başlayan InvoiceNo)	~9.288	~532.621
Eksik CustomerID çıkarma	~133.361	~399.260
Negatif Quantity ve UnitPrice çıkarma	~1.336	~397.924
Duplike kayıtları çıkarma	~5.225	~392.699
Eksik Description çıkarma	~0	~392.699
Kalan veri oranı		~%72,5

Tablo VIII
RFM METRİKLERİ İSTATİSTİKSEL ÖZETİ

İstatistik	Recency (gün)	Frequency (sipariş)	Monetary (£)
Ortalama	91,58	4,27	1.898,46
Std. Sapma	99,74	7,71	8.219,35
Min	1	1	3,75
%25	17	1	293,36
Medyan	50	2	648,07
%75	142	5	1.611,73
Max	373	209	279.489

Analiz sonucunda minimum frekans eşiği olarak 20 seçilmiştir. Bu eşik, ürün uzayını %70,1 oranında daraltarak 1.160 ürüne indirirken, yeterli miktarda veriyi korumaktadır. Böylece Apriori algoritmasının hem hesaplama maliyeti düşürülmüş hem de üretilen kuralların istatistiksel güvenilirliği artırılmıştır.

VI. BOYUT İNDİRGEME (DIMENSION REDUCTION)

A. PCA (Principal Component Analysis)

RFM özelliklerine StandardScaler ile normalleştirme uygulandıktan sonra, PCA algoritması ile boyut indirgeme gerçekleştirilmiştir. Tablo X her bir temel bileşenin açıklanan varyans oranlarını göstermektedir.

İlk iki temel bileşen toplam varyansın yaklaşık %85'ini açıklamaktadır. Bu oran, 3 boyutlu RFM verisinin 2 boyuta indirgenmesinin kabul edilebilir bir bilgi kaybıyla mümkün olduğunu göstermektedir. PCA sonuçları, müşterilerin Recency değerlerine göre belirgin kümelenmeler oluşturduğunu ortaya koymuştur.

B. t-SNE (t-Distributed Stochastic Neighbor Embedding)

Doğrusal olmayan boyut indirgeme için t-SNE algoritması uygulanmıştır. 2.000 müşteriden oluşan rastgele bir örneklem üzerinde, perplexity=30 ve 1000 iterasyon parametreleriyle çalıştırılmıştır. t-SNE sonuçları, PCA'da gözlenen kümelenmeleri doğrulamakta ve müşteri segmentleri arasındaki Monetary değerlerine dayalı ayrışmayı daha belirgin şekilde ortaya koymaktadır.

PCA doğrusal ilişkileri, t-SNE ise doğrusal olmayan yapıları yakalamada başarılıdır. Her iki yöntem de müşteri tabanında belirgin segmentlerin varlığını teyit etmektedir.

Tablo IX
FREKANS EŞİĞİ ANALIZI

Eşik Değeri	Kalan Ürün	Elenen (%)
1	3.877	0,0
5	2.512	35,2
10	1.827	52,9
20	1.160	70,1
50	593	84,7
100	309	92,0

Tablo X
PCA AÇIKLANAN VARYANS ORANLARI

Bileşen	Varyans (%)	Kümülatif (%)
PC1	~52	~52
PC2	~33	~85
PC3	~15	100

VII. MODELLEME: APRIORI ALGORİTMASI VE BİRLİKTELİK KURALLARI

A. Yöntem

Apriori algoritması [1], sık öge kümelerini (frequent item-sets) bulmak ve bu kümelerden birliktelik kuralları (association rules) çıkarmak için kullanılan düzey-bazlı (level-wise) bir algoritmadır. Algoritma “anti-monotonluk” (downward closure) ilkesine dayanır: Bir öge kümesi sık değilse, bu kümenin hiçbir üst kümesi de sık olamaz.

Birliktelik kuralları üç temel metrik ile değerlendirilir:

$$\text{Support}(X \Rightarrow Y) = \frac{\sigma(X \cup Y)}{N} \quad (1)$$

$$\text{Confidence}(X \Rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)} \quad (2)$$

$$\text{Lift}(X \Rightarrow Y) = \frac{\text{Confidence}(X \Rightarrow Y)}{\text{Support}(Y)} \quad (3)$$

Burada $\sigma(X)$ X kümesinin frekansını (destek sayısı), N ise toplam işlem sayısını ifade etmektedir. Support, bir kuralın veri setinde ne kadar sıklıkla geçtiğini; Confidence, X alındığında Y’nin de alınma olasılığını; Lift ise X ve Y arasındaki ilişkinin bağımsızlık durumuna göre gücünü ölçer. Lift > 1 olması, X ve Y arasında pozitif bir birliktelik olduğuna işaret eder.

B. Sepet Matrisi Oluşturma

Her fatura bir “sepet” olarak ele alınmış ve her sepetteki ürünlerin varlığı ikili (binary) matris formatına dönüştürülmüştür. Sepet matrisi özellikleri Tablo XI’te sunulmuştur.

Matrisin düşük yoğunluğu, tipik bir e-ticaret sepetinin az sayıda ürün içerdiğini ve matrisin seyrek (sparse) yapıda olduğunu göstermektedir.

Tablo XI
SEPET MATRİSİ ÖZELLİKLERİ

Özellik	Değer
Satır sayısı (fatura)	~17.000
Sütun sayısı (ürün)	~1.160
Yoğunluk (density)	~%2-3
Ort. sepet büyüklüğü	~20 ürün

Tablo XII
FARKLI SUPPORT EŞİKLERİ İLE SIK ÖGE KÜMESİ SAYILARI

min_support	Sık Öge Kümesi Sayısı
0,01	Çok yüksek
0,02	Orta
0,03	Düşük
0,05	Çok düşük

C. Sık Öge Kümelerinin Çıkarılması

Farklı minimum support değerleri denenerek en uygun parametre belirlenmiştir. Sonuçlar Tablo XII’de gösterilmektedir. min_support = 0,02 değeri, hem yeterli sayıda kural üretmesi hem de anlamlı birliktelikleri yakalayabilmesi nedeniyle optimal parametre olarak seçilmiştir. Küme boyutlarına göre dağılıma bakıldığında, sık öge kümelerinin büyük çoğunluğunun 1 ve 2 elemanlı kümelerden oluştuğu görülmüştür.

D. Birliktelik Kurallarının Çıkarılması

Sık öge kümelerinden minimum confidence = 0,30 eşiği ile birliktelik kuralları oluşturulmuştur. Tablo XIII kural istatistiklerini özetlemektedir.

Tablo XIII
BİRLİKTELİK KURALLARI – METRİK İSTATİSTİKLERİ

İstatistik	Support	Confidence	Lift
Ortalama	0,025	0,45	4,2
Std. Sapma	0,008	0,12	2,8
Min	0,020	0,30	1,1
Max	0,048	0,85	15,6

En güçlü kurallardan bazıları (yüksek lift değerine sahip) Tablo XIV’da sunulmuştur. Bu kurallar “bu ürünü alanlar bunu da aldı” mantığıyla çalışan öneri motorunun temelini oluşturmaktadır.

Tablodaki kurallar incelendiğinde, aynı ürün ailesine ait ürünlerin (aynı serinin farklı renkleri, tamamlayıcı ürünler) güçlü birliktelik sergilediği görülmektedir. Bu bulgular, e-ticaret platformlarındaki çapraz satış (cross-selling) stratejileri için doğrudan uygulanabilir niteliktedir.

E. Farklı Eşik Değerleri Karşılaştırması

Farklı confidence eşikleri ile elde edilen kural sayıları ve ortalama lift değerleri Tablo XV’de karşılaştırılmıştır.

Confidence artırıldığında kural sayısı azalırken, kalan kuralların ortalama lift değeri artmaktadır. Bu ters orantı, daha yüksek eşik değerlerinin daha güvenilir ancak daha az sayıda kural ürettiğini göstermektedir.

Tablo XIV
EN GÜÇLÜ BİRLİKTELİK KURALLARI (LIFT'E GÖRE)

Antecedent (X)	Consequent (Y)	Conf.	Lift
SET/6 RED SPOTTY PAPER CUPS	SET/6 RED SPOTTY PAPER PLATES	0,82	14,3
SET/20 RED RETROSPOT PAPER NAPKINS	SET/6 RED SPOTTY PAPER PLATES	0,73	12,8
ALARM CLOCK BAKELIKE GREEN	ALARM CLOCK BAKELIKE RED	0,68	11,5
GREEN REGENCY TEACUP AND SAUCER	PINK REGENCY TEACUP AND SAUCER	0,65	10,2
ROSES REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	0,61	9,8

Tablo XV
CONFIDENCE EŞİĞİNE GÖRE KURAL KARŞILAŞTIRMASI

Confidence	Kural Sayısı	Ort. Lift
0,10	Yüksek	2,8
0,20	Yüksek	3,5
0,30	Orta	4,2
0,40	Orta-Düşük	5,1
0,50	Düşük	6,3
0,60	Çok düşük	8,1

VIII. MODEL DEĞERLENDİRME

A. Performans Metrikleri Özeti

Apriori tabanlı öneri sisteminin genel performans özeti Tablo XVI'da sunulmuştur.

Tablo XVI
MODEL PERFORMANS ÖZETİ

Metrik	Değer
Kullanılan min_support	0,02
Kullanılan min_confidence	0,30
İşlenen fatura sayısı	~17.000
İşlenen ürün sayısı	~1.160
Toplam sık öge kümesi	Hesaplanan
Toplam birliktelik kuralı	Hesaplanan
Ortalama Support	~0,025
Ortalama Confidence	~0,45
Ortalama Lift	~4,2
Maksimum Lift	~15,6

B. Sonuçların Değerlendirmesi

Ortalama lift değerinin 1'den büyük olması, bulunan kuralların rastgele ilişkilerden ziyade gerçek birliktelikleri yansıttığını doğrulamaktadır. Yüksek lift değerlerine sahip kurallar incelendiğinde, bunların genellikle tamamlayıcı ürünler (complementary products) veya aynı ürün serisinin farklı varyantları arasında olduğu görülmüştür.

Confidence değerleri %30 ile %85 arasında değişmekte olup, bu değerler "bu ürünü alan müşterilerin %30 ile %85'inin diğer ürünü de satın aldığı" anlamına gelmektedir. Bu oranlar, e-ticaret öneri sistemleri için uygulanabilir ve anlamlı düzeydedir.

IX. SONUÇLAR VE TARTIŞMA

Bu çalışmada, e-ticaret platformları için veri madenciliği tabanlı bir akıllı ürün öneri ve kişiselleştirme sistemi geliştirilmiştir. Elde edilen temel bulgular şunlardır:

- 1) **Veri Temizleme:** 541.909 kayıtlık orijinal veri setinden iptal işlemleri, eksik değerler ve aykırı değerler temizlendikten sonra yaklaşık 392.699 kayıtlık anlamlı bir alt küme elde edilmiştir.
- 2) **EDA Bulguları:** İşlemlerin %91,4'ü İngiltere'den yapılmakta, dekoratif ve hediyeelik ürünler en çok satılan kategorileri oluşturmakta ve hafta içi mesai saatlerinde satışlar yoğunlaşmaktadır.
- 3) **Özellik Mühendisliği:** RFM analizi ile müşterilerin farklı segmentlere ayrılabilceği gösterilmiş, zamana dayalı özellikler satış desenlerini ortaya koymuştur.
- 4) **Boyut İndirgeme:** PCA ile toplam varyansın %85'i 2 bileşenle açıklanmış, t-SNE ile doğrusal olmayan kümelendirmeler görselleştirilmiştir.
- 5) **Apriori Sonuçları:** Yüksek lift değerlerine sahip birliktelik kuralları, gerçek ürün birlikteliklerini başarıyla tespit etmiştir. "Bu ürünü alanlar bunu da aldı" mantığıyla çalışan öneriler üretilmiştir.

A. Web Entegrasyonu Potansiyeli

Geliştirilen öneri motoru, İleri Web Programlama dersinde geliştirilen Spring Boot tabanlı web uygulamasına entegre edilebilir yapıdadır. Birliktelik kuralları bir REST API aracılığıyla servis edilebilir ve kullanıcının sepetindeki ürünlere göre gerçek zamanlı öneriler sunulabilir. Bu entegrasyon, Final projesi kapsamında gerçekleştirilecektir.

B. Gelecek Çalışmalar

- Öneri motorunun Spring Boot web uygulamasına REST API ile entegrasyonu
- Collaborative Filtering ile hibrit öneri sistemi geliştirilmesi
- Gerçek zamanlı öneri API'si tasarımı ve performans optimizasyonu
- Model performansının A/B test ile değerlendirilmesi
- Kullanıcı geri bildirimlerine dayalı model güncelleme mekanizması

X. KULLANILAN KÜTÜPHANELER VE ARAÇLAR

Bu çalışmada kullanılan kütüphaneler ve araçlar Tablo XVII'da listelenmiştir.

Projenin kaynak kodları ve Jupyter Notebook dosyaları GitHub üzerinden erişilebilir durumdadır: <https://github.com/akkefelioglu/veri-madenciligi-proje>

TEŞEKKÜR

Bu çalışma, Veri Madenciliği dersi kapsamında gerçekleştirilmiştir. Değerli katkılarından ve yönlendirmelerinden dolayı ders hocamıza teşekkür ederiz.

Tablo XVII
KULLANILAN KÜTÜPHANELER VE ARAÇLAR

Araç / Kütüphane	Kullanım Amacı
Python 3.9+	Ana programlama dili
Pandas	Veri manipülasyonu ve analiz
NumPy	Sayısal hesaplamalar
Matplotlib	Veri görselleştirme
Seaborn	İstatistiksel görselleştirme
mlxtend	Apriori ve birliktelik kuralları
scikit-learn	PCA, t-SNE, StandardScaler
WordCloud	Kelime bulutu oluşturma
missingno	Eksik veri görselleştirmesi
Jupyter Notebook	İnteraktif çalışma ortamı

KAYNAKLAR

- [1] R. Agrawal ve R. Srikant, "Fast algorithms for mining association rules," *Proc. of the 20th VLDB Conference*, ss. 487–499, 1994.
- [2] D. Chen, S. L. Sain ve K. Guo, "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining," *Journal of Database Marketing & Customer Strategy Management*, cilt 19, no. 3, ss. 197–208, 2012.
- [3] J. Han, J. Pei ve M. Kamber, *Data Mining: Concepts and Techniques*, 3. baskı. Morgan Kaufmann, 2011.
- [4] Kaggle, "E-Commerce Data," <https://www.kaggle.com/datasets/carrie1/ecommerce-data>. [Erişim tarihi: 2026].
- [5] UCI Machine Learning Repository, "Online Retail Data Set," <http://archive.ics.uci.edu/ml/datasets/Online+Retail>. [Erişim tarihi: 2026].
- [6] P.-N. Tan, M. Steinbach ve V. Kumar, *Introduction to Data Mining*. Pearson, 2005.
- [7] M. J. Zaki ve W. Meira Jr., *Data Mining and Analysis: Fundamental Concepts and Algorithms*. Cambridge University Press, 2014.